

مبانی داده کاوی

تمرین سوم – Classification & Clustering

بخش ۱ – Clustering :

در این بخش، هدف کلی اجرای الگوریتم‌های مختلف خوشه‌بندی روی دیتاست است. در ابتدا بررسی کنید که آیا دیتاستی که در اختیار دارید قابل خوشه‌بندی شدن می‌باشد یا خیر. اگر بله، سعی کنید تا تعداد خوشه‌ها را با توجه به مطالبی که در درس آموخته‌اید، پیدا کنید. پس از اجرای الگوریتم‌های مختلف خوشه‌بندی، هر خوشه را تحلیل کنید و توضیح دهید هر خوشه چه ویژگی‌هایی دارد و چه تفاوتی با سایر خوشه‌ها دارد. برای الگوریتم‌های k-means, k-medoids, k-median, fuzzy c-mean, kernel k-means, bisecting k-means, DBScan, OPTICS و HDBScan(Hierarchical DBScan) خوشه‌بندی را انجام دهید و هر کدام را براساس میزان مقاومت نسبت به نویز، توانایی تشخیص داده‌های غیرخطی و ... با یکدیگر مقایسه کنید. در نهایت براساس معیارهای ارزیابی مناسب و **استدلال منطقی**، بهترین مدل را برای دیتاست خود پیدا کنید. برای نمایش خوشه‌ها از رسم نمودار با کتابخانه‌های مناسب استفاده کنید.

بخش ۲ – Classification :

در این بخش، ابتدا باید یک ویژگی گسسته مناسب برای انتخاب آن به عنوان ستون هدف یا label انتخاب کنید (با در صورت نیاز بسازید) و سعی کنید تا با کمک داده‌های train و test، مدلی برای پیش‌بینی این ستون ارائه دهید. در این بخش باید از الگوریتم‌هایی مانند Decision Tree, Linear Regression, Naive Bayes و Random Forest استفاده کنید. پس از پیدا کردن بهترین مدل بر اساس معیارهای ارزیابی مناسب، باید مدل را تحلیل کنید که بر چه اساسی در مورد یک داده test تصمیم‌گیری می‌کند. به عنوان مثال در درخت تصمیم باید برگ‌های ایجاد شده در این درخت را بررسی کنید و آنها را تحلیل کنید که چه چیزی را نشان می‌دهند.

بخش ۳ - نکات تمرین :

برای هر مدل، بررسی و تحلیل کنید که مدل چه میزان به نویز و داده‌های پرت حساس است و چگونه درمقابل این نوع داده‌ها مقاومت می‌کند.

برای ساخت مدل‌ها از **hyperparameter tuning** استفاده کنید.

برای بهتر کردن عملکرد مدل‌ها می‌توانید از **Ensemble** ها (**Boosting** و **Bagging**) استفاده کنید. درمورد **overfit** و **underfit** شدن مدل‌ها بحث کنید.

در انتخاب معیار ارزیابی دقت کنید. باید بتوانید استدلال منطقی درمورد معیاری که برای ارزیابی مدل‌تان انتخاب کرده‌اید (با توجه به دیتاستی که دارید)، داشته باشید

می‌توانید تمامی آموخته‌های خود در طول درس و تمرینات را در این بخش یا سایر بخش‌ها استفاده کنید (مانند ساخت ویژگی جدید، حذف ویژگی‌های تکراری، ادغام چند ویژگی و ...)

هدف اصلی این تمرین، تحلیل و یک نتیجه‌گیری کامل از دیتاستی است که در اختیارتان قرار گرفته است. پس بخش زیادی از نمره به تحلیل و فایل گزارش شما اختصاص دارد.

باید بتوانید برای بخش‌های مختلف پروژه‌تان، استدلال کافی برای درست بودنشان داشته باشید. پس در هر بخش که فکر می‌کنید تصمیمی که گرفته‌اید مبهم است و ممکن است مورد پرسش قرار گیرد، استدلال مناسب و قانع کننده برای آن داشته باشید.

در نهایت، در گزارشتان توضیح دهید چگونه می‌توان از روش‌هایی که در این تمرین آموختید، در جهت تحقق اهداف **data mining** گام برداشت (همچنین سعی کنید تا ارتباطی بین این تمرین و تمرین ۲ پیدا کنید که چگونه می‌توان از روش‌های استفاده شده در این تمرین، برای بهبود تمرین قبلی استفاده کرد).

استفاده از تمام آموخته‌هایتان از این درس (چه در طول کلاس و چه در تمرینات و کوییزها) مجاز است. استفاده از سایر مواردی که از این درس خارج بوده است، اگر به صورت منطقی و کاربردی از آن استفاده شود، می‌تواند **نمره مازاد** داشته باشد. دقت کنید که برای هر بخش که می‌خواهید از مواردی که خارج از درس بوده است استفاده کنید، ابتدا باید آن را با کمک مطالب آموخته شده در درس پیاده‌سازی کنید، سپس در کنار آن به پیاده‌سازی خلاقانه و خارج از محتوای درس و کلاس بپردازید.

در نهایت، فایل پایتون نوت‌بوک (ipynb) و گزارش (که باید تنها شامل تحلیل نتایج باشد) خود را زیپ کرده و با فرمت StudentName_StudentNumber_3.zip در vu ارسال کنید.